# 1. Ejercicio NiFi

a. Creación de un grupo (Process Group) dentro de NiFi con el nombre PEC-<NombreAlumno>

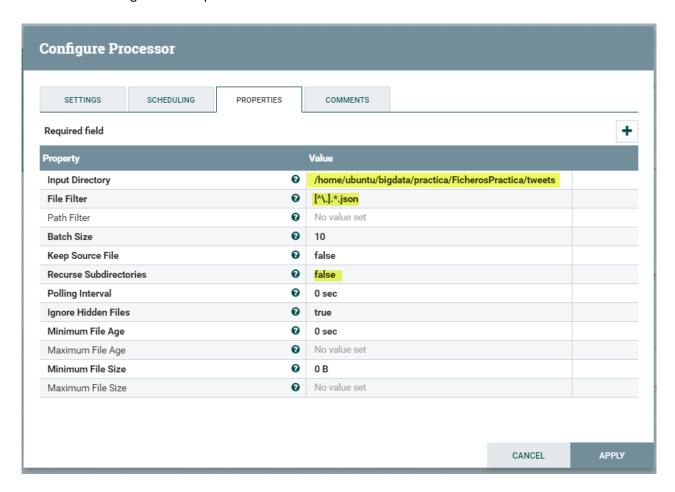




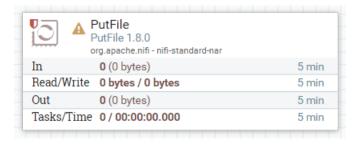
- b. Crear un flujo en NiFi que coja solo los ficheros de la carpeta tweets (del zip proporcionado) y **no** de sus subcarpetas y los deje en el directorio tweets/ejercicio
  - i. Creación de un proceso GetFile para recuperar los tweets



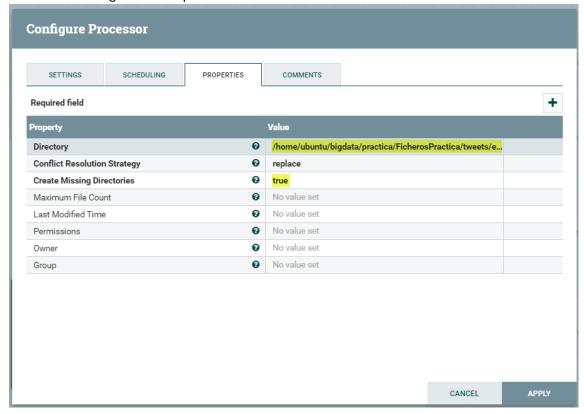
# ii. Configuración de proceso GetFile



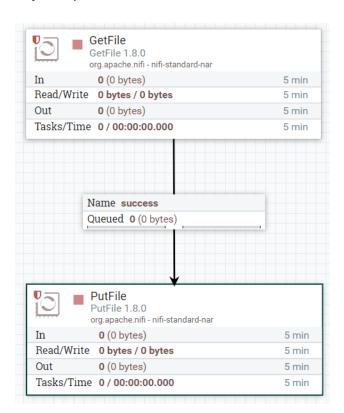
# iii. Creación de proceso PutFile



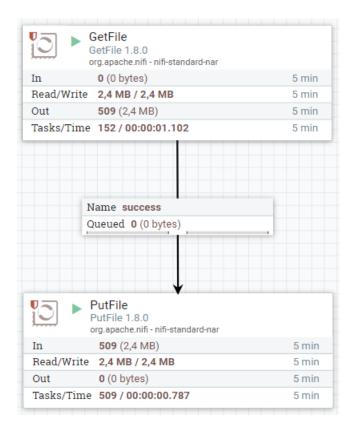
# iv. Configuración de proceso PutFile



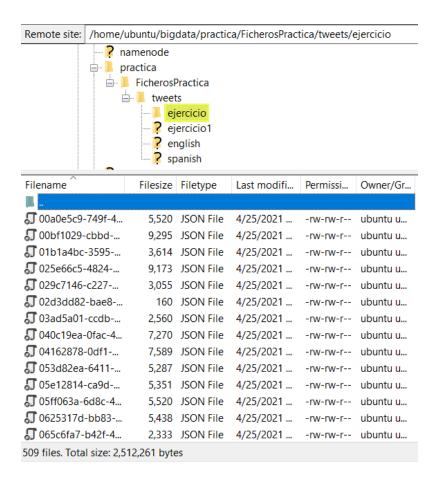
# v. Flujo completo



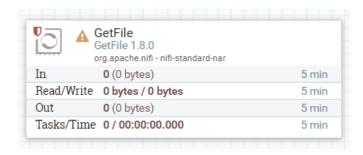
#### vi. Resultados



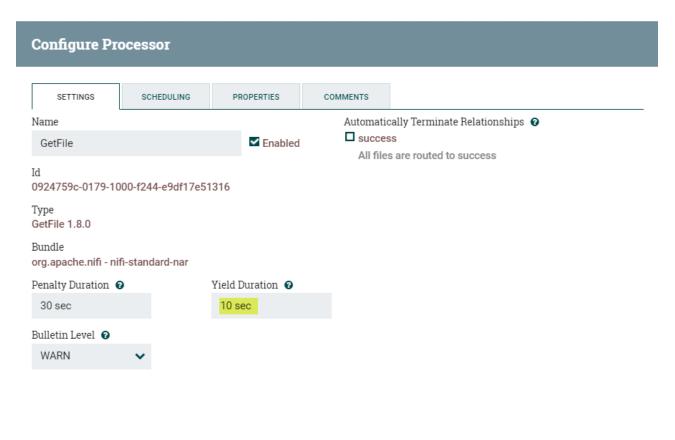
### vii. Resultados en Filezilla



- c. Crear un nuevo flujo que coja los tweets de 5 en 5 de la carpeta tweets/english cada 10 segundos y los deje de nuevo en el directorio tweets/ejercicio
  - i. Creación de proceso GetFile

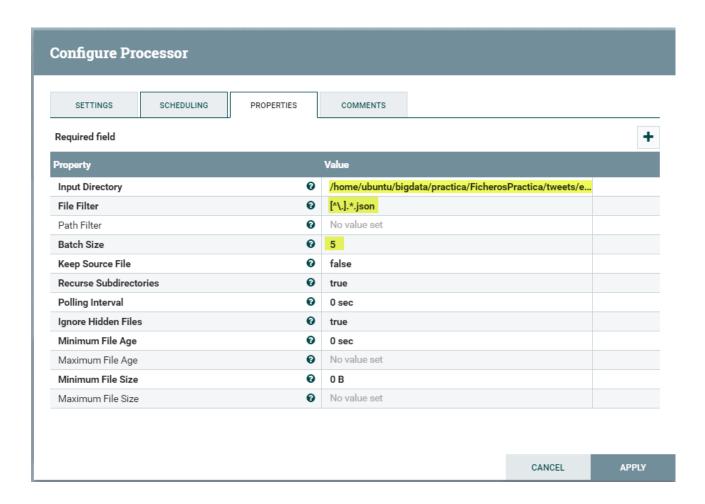


ii. Configuración de proceso GetFile

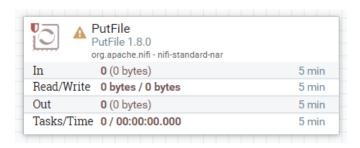


CANCEL

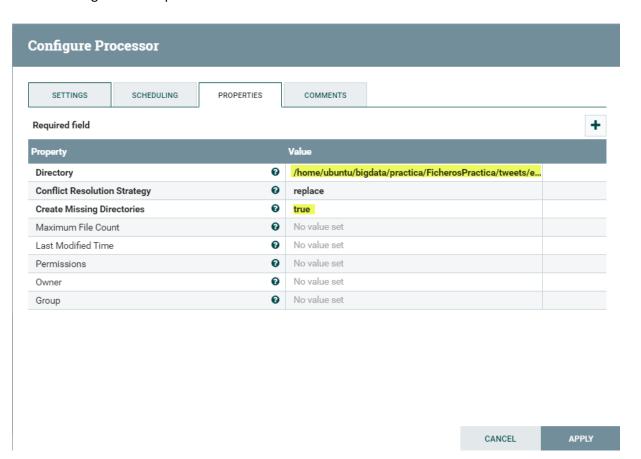
APPLY



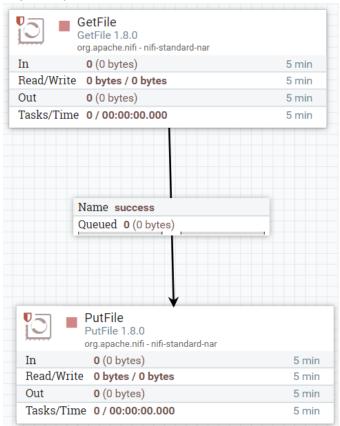
# iii. Creación de proceso PutFile



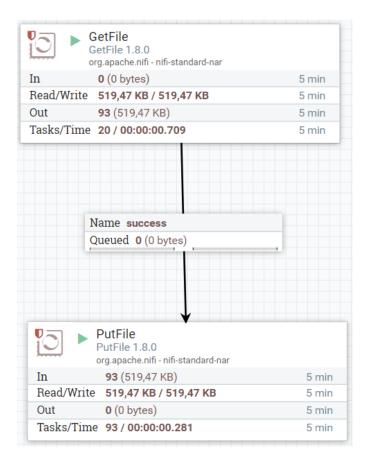
# iv. Configuración de proceso PutFile



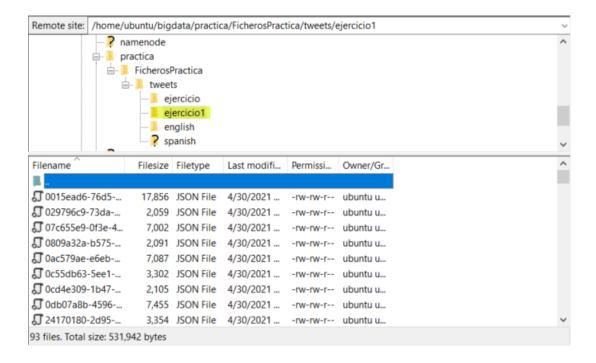
# v. Flujo Completo



#### vi. Resultados



#### vii. Resultados Filezilla



# 2. Ejercicio SparkSQL

a. Cargar los datos del fichero dataset\_coches.csv en un dataframe y mostrar las primeras 5 líneas del dataframe.

```
In [1]:
          datosCoches = spark.read.format('csv') \
                    .option('header','true') \
                    .option('inferSchema','true') \
                    .option('delimiter', ';') \
                    .load(ruta + "/dataset_coches.csv")
In [2]:
       datosCoches.show(5)
          +-----
                       Car | MPG | Cylinders | Displacement | Horsepower | Weight | Acceleration | Model | Origin |
            -----
          | Chevrolet Chevell...|18.0| 8| 307.0| 130.0| 3504| 12.0| | Buick Skylark 320|15.0| 8| 350.0| 165.0| 3693| 11.5| | Plymouth Satellite|18.0| 8| 318.0| 150.0| 3436| 11.0| | AMC Rebel SST|16.0| 8| 304.0| 150.0| 3433| 12.0| | Ford Torino|17.0| 8| 302.0| 140.0| 3449| 10.5|
                                                                                    US
                                                                               70
                                                                                    US
                                                                               70
                                                                                    US
                                                                               70
                                                                                    usl
          +-----+
         only showing top 5 rows
```

- b. Usando tanto SQL como el API de dataframes de Spark obtener las columnas "Car" y "Cylinders" de todos los que sean de Europa
  - i. SparkSQL Dataframe API

only showing top 20 rows

```
In [6]: | from pyspark.sql.functions import count, desc, avg
           europeCars = datosCoches.where("Origin == 'Europe'")
           selectEropeCars = europeCars.select(europeCars['Car'].alias('Car'), europeCars['Cylinders'].alias('Cylinders'))
           selectEropeCars.show()
           +----+
                 Car|Cylinders|
           ·----+-----
           |Citroen DS-21 Pallas| 4|
           |Volkswagen 1131 D...|
                   Peugeot 504
                   Audi 100 LS
                      Saab 99e
                      BMW 2002
                                     4
           |Volkswagen Super ...|
                     Opel 1900
                   Peugeot 304
                     Fiat 124B
           |Volkswagen Model 111|
                                     4
              Volkswagen Type 3
               Volvo 145e (sw)
            Volkswagen 411 (sw)
                                     4
               Peugeot 504 (sw)
               Renault 12 (sw)
           |Volkswagen Super ...|
                                     4
           |Fiat 124 Sport Coupe|
                     Fiat 128
                  Opel Manta
```

ii. SQL

```
In [13]:

    ■ datosCoches.createOrReplaceTempView("carsSQL")

         M rset = spark.sql("SELECT Car, Cylinders FROM carsSQL where Origin == 'Europe'")
In [14]:
            rset.show()
             +----+
                            Car|Cylinders|
             |Citroen DS-21 Pallas|
             |Volkswagen 1131 D...|
                     Peugeot 504
                                        4
                      Audi 100 LS
                         Saab 99e
                        BMW 2002
             |Volkswagen Super ...|
                                        4
                                        4
                        Opel 1900
                                        4
                      Peugeot 304
                        Fiat 124B
                                        4
             |Volkswagen Model 111|
                Volkswagen Type 3
                                         4
                  Volvo 145e (sw)
                                         4
              Volkswagen 411 (sw)
                 Peugeot 504 (sw)|
                  Renault 12 (sw)
             | Volkswagen Super ...|
             |Fiat 124 Sport Coupe|
                                        4
                        Fiat 128
                       Opel Manta
            only showing top 20 rows
```

- c. Usando tanto SQL como el API de dataframes de Spark obtener el número de vehículos por "Origin"
  - i. SparkSQL Dataframe API

# 3. Ejercicio Kafka

- a. Creación de topics
  - i. Crear un nuevo topic denominado pec-topic1-<NombreAlumno> con dos particiones y con factor de replicación 1

```
(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic pec-topic1-Saulo --create --partitions 2 --replication-factor 1 Created topic "pec-topic1-Saulo".

(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-topics.sh --zookeeper 127.0.0.1:2181 --list
__confluent.support.metrics
__consumer_offsets
pec-topic1-Saulo
```

```
(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic pec-topic1-Saulo --describe
Topic:pec-topic1-Saulo PartitionCount:2 ReplicationFactor:1 Configs:
Topic: pec-topic1-Saulo Partition: 0 Leader: 1 Replicas: 1 Isr: 1
Topic: pec-topic1-Saulo Partition: 1 Leader: 2 Replicas: 2 Isr: 2
```

ii. ¿Sería posible crearlo en el entorno que tienes con un factor de replicación de 2? ¿Por qué?

Nuestra arquitectura contiene 3 Brokers/Nodos y podria soportar un factor de replicación de 2.

```
(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic pec-topic1-Saulo2 --create --partitions 2 --replication-factor Created topic "pec-topic1-Saulo2".

(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic pec-topic1-Saulo2 --describe Topic:pec-topic1-Saulo2 PartitionCount:2 ReplicationFactor:2 Configs:

Topic: pec-topic1-Saulo2 Partition: 0 Leader: 2 Replicas: 2,3 Isr: 2,3
Topic: pec-topic1-Saulo2 Partition: 1 Leader: 3 Replicas: 3,1 Isr: 3,1
```

b. Crea un productor que empiece a pasar información desde la línea de comandos al topic creado anteriormente y simular el envío de información

```
(base) ubuntu@master-1:~/Docker/kafka-docker-compose$ kafka-console-producer.sh --broker-list 127.0.0.1:9092 --topic
ec-topic1-Saulo
>This is a test
>tes1
>test2
>bye
```

- c. Creación de consumidores
  - i. Crear un consumidor que sea capaz de leer *toda* la información que contenga el topic creado

```
(base) ubuntu@master-1:~$ kafka-console-consumer.sh --bootstrap-server 127.0.0.1:9092 --topic pec-topic1-Saulo
This is a test
tes1
test2
bye
^CProcessed a total of 4 messages
```

# 4. Ejercicio Spark Streaming

- a. Saber en tiempo real cuantas veces pasa un vehículo por cada punto del sistema desde el día que se pone en marcha el mecanismo.
  - i. Iniciar el Producer

```
(base) ubuntu@master-1:~/bigdata/examples/spark/sparkStreaming$ python vehiculos_producer.py --port 9997 --interval 5
Listening at ('localhost', 9997)
```

ii. Script para conectarse al stream y procesar las lineas

# Es necesario tener HDFS arrancado, guarda información (sólo si no ponemos ruta local)

### iii. Resultados

```
In [6]:
           M ssc.start()
              Time: 2021-04-29 18:45:20
              Matriculas
              ( 1234AAA A7-KM-50', 2)
                                         Cantidad de veces que
              ( 1234AAA A7-KM-01 , 3)
                                         paso este Vehiculo por
Puntos de Control ( 1234EEE A7-KM-50 , 1)
                                         este punto de control
              ( 1234AAA A7-KM-30', 2)
              ( 1234UUU A7-KM-15', 1)
              ( 1234UUU A7-KM-30'
               1234EEE A7-KM-30
              Time: 2021-04-29 18:45:30
              ('1234AAA A7-KM-50', 2)
              ('1234AAA A7-KM-01', 3)
              ('1234EEE A7-KM-50', 1)
              ('1234AAA A7-KM-30', 2)
              ('1234UUU A7-KM-15', 2)
```

- b. Saber en tiempo real cuántas veces pasa un vehículo por un determinado punto, pero solo teniendo en cuenta los últimos 7 días de información.
  - i. Script para conectarse y procesar las líneas.

```
In []: M sc.stop()
sc = SparkContext(appName="NetWordCountStateWindow")
ssc = StreamingContext(sc, 100)
```

# Es necesario tener HDFS arrancado, guarda información (sólo si no ponemos ruta local)

#### ii. Resultados

Los resultados son similares al apartado anterior. Sin embargo, esperaríamos que transcurrido el tiempo de la ventana temporal, estos datos se actualicen.

```
In [6]:  ★ ssc.start()
             Time: 2021-04-29 18:45:20
             Matriculas
             ( 1234AAA A7-KM-50', 2)
                                     Cantidad de veces que
             ( 1234AAA A7-KM-01', 3)
                                      paso este Vehiculo por
Puntos de Control ( 1234EEE A7-KM-50 , 1)
                                      este punto de control
             ( 1234AAA A7-KM-30 , 2)
             ( 1234UUU A7-KM-15', 1)
              1234UUU A7-KM-30',
                                 1)
             ( 1234EEE A7-KM-30', 1)
             Time: 2021-04-29 18:45:30
             _____
             ('1234AAA A7-KM-50', 2)
             ('1234AAA A7-KM-01', 3)
             ('1234EEE A7-KM-50', 1)
             ('1234AAA A7-KM-30', 2)
             ('1234UUU A7-KM-15', 2)
```